

Rapport de Projet : Architecture et Chargement de Données avec Amazon Redshift

Auteur : Boubacar Djibrilla

Rôle : Ingénieur Logiciel Full-Stack

Date : 19 Juillet 2026

Description du Projet : Ce document récapitule l'implémentation complète d'un pipeline d'intégration de données (ETL) exploitant un Data Lake Amazon S3 et un entrepôt de données Amazon Redshift (Configuration Mono-nœud), entièrement sécurisé par des politiques de contrôle d'accès IAM.

1. Architecture Globale du Pipeline

Le flux de données conçu et validé au cours de ce projet s'articule autour des composants AWS suivants :

- **Source de Données (Data Lake) :** Un compartiment Amazon S3 privé contenant le jeu de données extrait au format CSV (consumers-price-index-march-2026-quarter-index-numbers.csv).
- **Sécurité & Autorisations :** Un rôle IAM personnalisé (redshift-roles) configuré pour accorder à Redshift les privilèges nécessaires à l'interrogation et à la lecture du stockage S3.
- **Cible (Data Warehouse) :** Un cluster Amazon Redshift composé d'un unique nœud de calcul (node = 1), fournissant un moteur d'exécution massivement parallèle (MPP).
- **Interface d'Administration :** Le Query Editor v2 d'Amazon Redshift pour l'exécution des scripts de définition de données (DDL) et des commandes d'injection (DML).

2. Guide Étape par Étape et Résolution des Incidents

Étape 1 : Configuration des Rôles et Droits d'Accès (AWS IAM)

Pour permettre à Amazon Redshift d'accéder aux données hébergées sur Amazon S3, un rôle de confiance spécifique a été déployé.

- **Nom du rôle :** redshift-roles
- **ARN du rôle :** arn:aws:iam::110753465874:role/redshift-roles
- **Politiques attachées :**
 - AmazonS3FilesFullAccess
 - AmazonS3ReadOnlyAccess (Indispensable pour résoudre l'erreur initiale s3:ListBucket rencontrée lors de la phase de découverte du bucket par le nœud

maître de Redshift).

Étape 2 : Préparation et Stockage des Données (Amazon S3)

1. Création d'un bucket d'infrastructure privé nommé redshiftbktdjibril.
2. Conversion du fichier source (initialement au format Excel non supporté .xlsx) au format normalisé textuel .csv.
3. Téléversement du fichier finalisé :
consumers-price-index-march-2026-quarter-index-numbers.csv à la racine du bucket.

Étape 3 : Instanciation du Data Warehouse (Amazon Redshift)

- Déploiement d'un cluster managé sous l'identifiant redshift-cluster.
- Dimensionnement : Configuration **Single-Node (1 nœud)** pour des raisons d'optimisation budgétaire.
- Association explicite du rôle IAM redshift-roles dans les propriétés du cluster pour activer l'authentification croisée entre services AWS.

Étape 4 : Modélisation et Chargement via le Query Editor v2

En raison de la présence de caractères spéciaux (tiret du milieu -) dans le nommage ciblé, la table a été créée en appliquant des identificateurs délimités par des guillemets doubles ("consumers-price").

Script de structure DDL (Création de la table) :

```
CREATE TABLE dev.public."consumers-price" (  
    series_reference VARCHAR(50),  
    period NUMERIC(10,2),  
    data_value NUMERIC(15,6),  
    status VARCHAR(20),  
    units VARCHAR(20),  
    subject VARCHAR(50),  
    series_group VARCHAR(100),  
    series_title_1 VARCHAR(150),  
    series_title_2 VARCHAR(150)  
);
```

Commande d'Ingestion COPY optimisée :

Note de résolution : La commande intègre l'instruction NULL AS 'NA' pour éviter le crash de l'importation sur la ligne 13868 provoqué par la présence de chaînes textuelles 'NA' au sein de la colonne numérique data_value.

```
COPY dev.public."consumers-price"  
FROM  
's3://redshiftbktdjibril/consumers-price-index-march-2026-quarter-index-numbers.csv'
```

```

IAM_ROLE 'arn:aws:iam::110753465874:role/redshift-roles'
FORMAT AS CSV
DELIMITER ','
IGNOREHEADER 1
NULL AS 'NA';

```

Requête de Validation des Données :

```
SELECT * FROM dev.public."consumers-price" LIMIT 10;
```

3. Procédure de Nettoyage et de Décommissionnement

Pour assurer une gestion rigoureuse des coûts cloud après validation des étapes du TP, les ressources doivent être purgées selon l'ordre suivant :

Service	Ressource	Action de Suppression
Amazon Redshift	redshift-cluster	Suppression complète (Sans snapshot final) pour stopper immédiatement la tarification horaire du nœud de calcul.
Amazon S3	redshiftbktdjibril	Vidage complet du contenu du bucket suivi de sa suppression définitive.
AWS IAM	redshift-roles	Révocation et suppression du rôle de sécurité pour maintenir l'environnement propre.

Fin du document technique. Ce pipeline valide les concepts fondamentaux du chargement de données à grande échelle au sein de l'écosystème AWS.